ХӨДӨЛМӨРИЙН ТУХАЙ ХУУЛИЙН ЛАВЛАХ ЧАТБОТЫГ ХАЙЛТААР БАГТААСАН ҮҮСГЭЛТИЙН (RAG) АРГААР, ЛОКАЛ ХИЙМЭЛ ОЮУНЫ ЗАГВАРААР БҮТЭЭСЭН НЬ

[Овог Нэр][1], [Удирдагч багшийн Овог Нэр][2]

Монгол улс, Эрдэнэт, ШУТИС, “Эрдэнэт цогцолбор” дээд сургууль
Холбогдох зохиогчийн и-мэйл хаяг: B231940123@eit.edu.mn

***Хураангуй*— Хөдөлмөрийн харилцааны талаар хүний нөөцийн ажилтан, ажилтан, ажил олгогч нар хуулийн заалтыг өдөр тутам лавлах шаардлагатай тулгардаг. Хөдөлмөрийн тухай хууль (шинэчилсэн найруулга) 166 зүйлтэй бөгөөд нөхцөл, үл хамаарах заалт ихтэй тул хүссэн заалтаа олж, зөв ойлгоход цаг их зарцуулдаг. Том хэлний загварт шууд асуувал хуулийн заалтыг санаанаасаа зохиох эрсдэлтэй. Иймээс энэхүү судалгаагаар хуулийн текстийг зүйл, заалтаар нь хуваан индексжүүлж, embedding болон BM25 хайлтыг нэгтгэсэн (hybrid) аргаар холбогдох заалтыг олж, зөвхөн олдсон заалтад тулгуурлан Монгол хэлээр хариулж, иш татсан зүйлийн дугаарыг заадаг, интернэтгүйгээр ажилладаг чатботын прототип бүтээв. Систем нь 4 GB GPU, 8 GB RAM бүхий зөөврийн компьютер дээр Ollama-гаар ажиллана. Туршилтыг тохируулалтын, хөгжүүлэлтийн, нэг удаа ажиллуулсан эцсийн гэсэн гурван түвшний асуултын багцаар хийв. Эцсийн 18 асуултын (хуульд байгаа 12, байхгүй 6) шалгалтаар зөв зүйлийг эхний байранд 92%, эхний тавд 100% олж, хуульд байгаа асуултын 75-83%-д зөв хариулсан. Харин хуульд байхгүй асуултын 33-50%-д л зөв татгалзаж, холбоотой үгтэй асуултад хуурамч хариулт зохиодог сул тал илэрлээ. Иймээс систем нь хуулийн зөвлөгөө бус, хариултыг эх заалттай нь тулгаж шалгах лавлах туслах түвшинд байна.**

***Түлхүүр үг*— RAG, хөдөлмөрийн хууль, hybrid хайлт, BM25, Qwen3, Ollama, Монгол хэл, хиймэл оюун**

I. Удиртгал

Хөдөлмөрийн харилцаа нь хүн бүрийн өдөр тутмын амьдралд нөлөөлдөг. Ажилтан ээлжийн амралт хэдэн өдөр авах, илүү цагийн нэмэгдэл хэд байх, ажлаас чөлөөлөгдөхөд ямар тэтгэмж авахыг, харин ажил олгогч, хүний нөөцийн ажилтан цалин, чөлөө, гэрээ цуцлалтын журмыг мөрдөхдөө хуулийн заалтыг байнга лавладаг. Гэтэл Хөдөлмөрийн тухай хууль (шинэчилсэн найруулга) 166 зүйл, мянга орчим заалттай, нэг асуултын хариулт нь хэд хэдэн зүйлд тархсан, мөн “…-аас бусад тохиолдолд” гэх мэт үл хамаарах нөхцөлтэй байдаг. Жишээлбэл ээлжийн амралтын үндсэн хугацаа (ажлын 15 өдөр), хөгжлийн бэрхшээлтэй ажилтны тусгай хугацаа, ажилласан жилээс хамаарсан нэмэгдэл өдрүүд нь нэг зүйлийн өөр өөр заалтад байна.

Том хэлний загварууд (LLM) асуултад чөлөөтэй хариулж чаддаг ч сургалтын өгөгдөлд байгаагүй мэдээллийг санаанаасаа зохиох (hallucination) эрсдэлтэй бөгөөд хариултынхаа эх сурвалжийг заадаггүй [6]. Хуулийн лавлагаанд буруу тоо, буруу нөхцөл нь шууд хохирол учруулж болно. Мөн ажилтны асуулт, компанийн дотоод журмыг гадаад үйлчилгээнд илгээх нь нууцлалын асуудал үүсгэнэ.

Хайлтаар баталгаажуулсан үүсгэлт (Retrieval-Augmented Generation, RAG) нь асуултад холбогдох баримтыг эхлээд хайж олоод, загварт зөвхөн тэр баримтыг үндэслэн хариулуулдаг арга юм [1]. Ийм системийн чанар нь хайлт, контекст сонголт, хариулт үүсгэлт гэсэн гурван хэсгийн хамгийн сул хэсгээр хязгаарлагддаг.

Бид (1) хуулийн зүйл, заалтын бүтцийг ашигласан хэсэглэлт, (2) embedding ба BM25 хайлтыг нэгтгэсэн hybrid хайлт, (3) заалтын түвшинд контекст сонгож, хариултын тоо, нөхцөлийг шалгадаг хамгаалалт, (4) тохируулалтын, хөгжүүлэлтийн, эцсийн гэсэн гурван түвшний шударга үнэлгээний протокол бүхий локал чатбот бүтээв. Мөн Монгол хэл, 4 GB GPU-ийн хязгаарлагдмал нөөцөд ажиллах үеийн алдааны төрлүүдийг задлан шинжиллээ.

II. Ижил төстэй судалгааны ажлууд

RAG-ийг Lewis болон бусад (2020) санал болгосон бөгөөд хэлний загварын параметрт хадгалагдсан мэдлэгийг гаднаас хайж олсон баримтаар нөхсөнөөр мэдлэг шаардсан даалгаварт үр дүнг сайжруулж, хариултыг эх баримттай холбох боломжтойг үзүүлсэн [1].

Хайлтын хувьд BM25 нь түлхүүр үгийн давтамж, баримтын уртыг харгалзан оноо өгдөг, өнөөг хүртэл хүчтэй суурь арга хэвээр байна [2]. Embedding нь үгээр таарахгүй ч утгаар ойр текстийг олдог. Хоёр төрлийн эрэмбийг нэгтгэх энгийн арга нь Reciprocal Rank Fusion (RRF) бөгөөд баримт бүрийн эрэмбийн урвуу утгыг нийлбэрлэн эцсийн эрэмбийг гаргана [3]. Qwen3 Embedding цуврал нь 0.6B, 4B, 8B хэмжээтэй, олон хэлэнд зориулагдсан embedding загварууд юм [4].

Qwen3 цуврал хэлний загвар нь 119 хэл, аялгууг дэмждэг бөгөөд thinking болон non-thinking гэсэн хоёр горимтой [5]. Бид хариулт үүсгэхэд Qwen3.5 цувралын 4B загварыг [10] ашигласан. Монгол хэл нөөц багатай хэл тул олон хэлний загварын чанар Монгол хэл дээр харьцангуй сул байх нь бидний туршилтаас ч харагдсан (IV хэсэг).

III. Хөгжүүлэлтийн хэсэг

Систем нь Python хэл дээр, NumPy болон Ollama [9] сангаар хийгдсэн, тусдаа вектор

өгөгдлийн сан ашигладаггүй, бүх тооцоо нь локал компьютер дээр явагддаг. Ажиллах дараалал нь: хуулийн текстийг зүйл, заалтаар хуваах; хэсэг бүрийг embedding болгож, BM25-ын хамт индексжүүлэх; асуултад hybrid хайлтаар холбогдох хэсгийг олох; олдсон зүйлүүдээс хамгийн холбоотой заалтыг сонгох; LLM-д өгч хариулт гаргуулах; хариултыг шалгаж, бүтэлгүйтвэл контекстыг томруулж дахин оролдох.

А. Өгөгдөл бэлтгэх

Эх сурвалж нь хуулийн албан ёсны Word файл [8]. Түүнийг текст болгон хөрвүүлж, форматын үлдэгдэл, бүлгийн гарчгийг цэвэрлэв. “N дүгээр зүйл.” гэсэн гарчгаар 166 зүйлийг, “N.M.” тэмдэглэгээгээр дэд заалтыг оруулаад нийт 988 заалтыг ялгав. Зүйл бүрийн урт нь хэдэн зуугаас таван мянга гаруй тэмдэгт хүртэл өөр өөр байна.

Б. Хэсэглэлт

Тэмдэгтийн тоогоор таслах нь нэг заалтыг хоёр хэсэгт хуваан утгыг алдагдуулдаг тул зүйлийг заалтын (догол мөрийн) хилээр, 600 тэмдэгтээс хэтрүүлэлгүй хуваав. Хэсэг бүрийн эхэнд “Зүйл N. гарчиг” гэсэн толгойг давтсанаар хэсэг дангаараа ч аль зүйлд хамаарахаа илэрхийлнэ. Үр дүнд 371 хэсэг үүссэн. Эхний туршилтаар 600 тэмдэгт нь 1200 тэмдэгтээс илүү сайн хайлттай гарсан.

В. Hybrid хайлт

Хайлт нь хоёр эрэмбийг нэгтгэнэ. Нэгдүгээрт, хэсэг бүрийг Qwen3-Embedding загвараар (Ollama-аар) вектор болгож, асуулттай косинус ойролцооллоор эрэмбэлнэ. Хоёрдугаарт, BM25-ыг үг бүрийн эхний дөрвөн үсгээр (stem) тооцно, учир нь Монгол хэлэнд үг нөхцөл залгаж хувирдаг (жишээ нь “хөлс”, “хөлсөнд”). Хоёр эрэмбийг RRF-ээр нэгтгэхдээ embedding-ийн жинг 0.3 гэж авсан. Түүнчлэн ярианы цөөн үгийг хуулийн үгтэй тааруулах гараар хийсэн жижиг толь ашигласан.

Г. Контекст сонголт ба хариулт үүсгэлт

Олдсон хэсгүүд нь олон зүйлийг хамарсан урт, шуугиантай байдаг тул жижиг загварт тохиромжгүй. Иймээс олдсон зүйлүүдийн заалтыг (дэд заалтыг оролцуулан) BM25-аар дахин эрэмбэлж, хамгийн холбоотой 5 заалтыг контекст болгон авна; хамгийн тохирох зүйлийн заалтын оноог 1.3 дахин нэмэгдүүлнэ. Хэрэв загвар “Мэдээлэл олдсонгүй” гэвэл эсвэл хариултын тоо баталгаажихгүй бол контекстыг 9 заалт болгож, түүнд ч бүтэлгүйтвэл олдсон хэсгүүдийг бүтнээр нь өгч дахин оролдоно.

Хариулт үүсгэхэд Qwen3.5 4B загварыг (thinking унтраасан, температур 0, seed 42, контекстийн цонх 4096) ашигласан. Prompt-ийн зааврыг англи хэлээр бичсэн бөгөөд: зөвхөн контекстийг ашиглах; асуултын тоо, нөхцөлийг заалттай харьцуулах; тусгай бүлгийн (насанд хүрээгүй, жирэмсэн гэх мэт) заалтыг асуултад дурдсан үед л хэрэглэх; үл хамаарах нөхцөлийг хамт хэлэх; асуултын сэдвийг контекст нэрлээгүй бол “Мэдээлэл олдсонгүй” гэх; хариултыг Монгол хэлээр, “Хариулт:” гэж эхлүүлж иш татсан зүйлийн дугаараар төгсгөх гэсэн дүрэм агуулна. Мөн “нэг жил”, “таван жил” гэх мэт тооны үгийг цифр болгож хөрвүүлээд асуулт ба контекстэд өгдөг.

Д. Хамгаалалтууд

Системд дөрвөн хамгаалалт бий. (1) Сэдвийн шалгалт: асуултын гол үгсийн (эхний 4 үсгээр) хагасаас олон нь олдсон контекстэд байхгүй бол загварыг дуудалгүйгээр “Мэдээлэл олдсонгүй” гэнэ. (2) Тусгай бүлгийн шүүлт: асуултад дурдаагүй бол насанд хүрээгүй, хөгжлийн бэрхшээлтэй, жирэмсэн зэрэг тусгай бүлэгт хамаарах заалтыг контекстээс хасна. (3) Тооны баталгаажуулалт: хариултад гарсан тоо контекст, асуултад байхгүй бол хариултыг хүлээн авахгүй; хуулийн “нэг аравны тав дахин” (0.5), “тэг аравны гурван хувь” (0.3%) гэх мэт бутархай хэллэгийн зөв тоон хэлбэрийг (0.5, 50%, 1.5) зөвшөөрнө. (4) Татгалзал: бүх оролдлого бүтэлгүйтвэл “Мэдээлэл олдсонгүй”, эсвэл “хариултын тоог баталгаажуулж чадсангүй” гэж харуулна.

Е. Үнэлгээний протокол

Системийг гурван түвшний асуултын багцаар хэмжив. Тохируулалтын багц (29 асуулт) дээр системийн параметрийг (жишээ нь embedding-ийн жин 0.3, толь) сонгосон тул үүнийг гүйцэтгэлийн үзүүлэлт болгохгүй. Хөгжүүлэлтийн хоёр багц (хуульд байгаа 27, байхгүй 8 асуулт) дээр сайжруулалт, prompt-ийн дүрмийг шалгав. Эцсийн багц (хуульд байгаа 12, байхгүй 6 асуулт) нь тохируулга хийх явцад ашиглагдаагүй бөгөөд нэг л удаа ажиллуулсан. Асуулт бүрийн зөв заалт, хариултын түлхүүр үгийг хуулийн текстээр баталгаажуулсан. Хайлтыг hit@k (зөв зүйл эхний k байранд орсон хувь) ба MRR-ээр, хариултыг түлхүүр үг болон зөв зүйл иш татсан эсэхээр скриптээр, мөн гараар уншиж үнэлсэн. Хуульд байхгүй асуултад зөв хариулт нь “Мэдээлэл олдсонгүй” байна. Хувь бүрт Вилсоны 95%-ийн итгэх завсрыг [7] тооцов. Туршилтыг RTX 3050 (4 GB VRAM), 8 GB RAM-тай зөөврийн компьютер дээр хийсэн.

IV. Судалгааны үр дүн

Эхлээд embedding загваруудыг хуулийн хайлт дээр харьцуулав (24 асуулт, 1200 тэмдэгтийн хэсэг, зөвхөн embedding хайлт). nomic-embed-text зөв зүйлийг эхний гурвын 42%-д, Qwen3-Embedding 0.6B 71%-д олсон (1-р хүснэгт). Энэ нь Монгол хэл дээр Qwen3-Embedding-ийг сонгох үндэслэл болов.

Загвар	hit@1	hit@3	hit@5	MRR
nomic-embed-text	29%	42%	46%	0.36
Qwen3-Embedding 0.6B	33%	71%	75%	0.51

1-р хүснэгт. Embedding загваруудын харьцуулалт (24 асуулт)

Бүрэн системийн хайлтын үр дүнг 2-р хүснэгтэд үзүүлэв. Тохируулалтын багц дээр 100% гарсан нь системийг тэр асуултуудад тааруулсны үр дүн тул гүйцэтгэлийн үзүүлэлт биш. Харин хөгжүүлэлтийн багц дээр зөв зүйлийг эхний байранд 74-78%, эхний гурвын 89-93%-д олсон нь бодит түвшинд ойр. 0.6B ба 4B загварын ялгаа 27 асуулт дээр статистикийн хувьд мэдэгдэхүйц биш (hit@3 93% ба 89%). Харин 4B нь 4 GB GPU дээр LLM-тэй зэрэг ачаалагдахад хариултын хугацааг 21-55 секунд болгож удаашруулсан (0.6B-тэй үед ойролцоогоор 8-34 секунд). Эцсийн шалгалтыг 4B-ээр хийсэн. Эцсийн багц дээр зөв зүйлийг эхний байранд 92% (11/12, 95%-ийн завсар 65-99%), эхний тавд 100% (12/12) олсон.

Багц	Embed.	hit@1	hit@3	hit@5	MRR
Тохируулалт (29)	0.6B	100%	100%	100%	1.00
Хөгжүүлэлт (27)	0.6B	74%	93%	93%	0.82
Хөгжүүлэлт (27)	4B	78%	89%	96%	0.86
Эцсийн (12)	4B	92%	92%	100%	0.94

2-р хүснэгт. Хайлтын үр дүн (хуульд байгаа асуултууд)

Хариултын зөв байдлыг 3-р хүснэгтэд үзүүлэв. Хөгжүүлэлтийн багц дээр хуульд байгаа асуултын 85% (23/27, завсар 68-94%), хуульд байхгүй асуултын 75% (6/8, завсар 41-93%)-д зөв хариулсан. Эцсийн багц дээр хуульд байгаа асуултын 75% (9/12, скриптээр), гараар уншихад 83% (10/12, завсар 55-95%) зөв байв; нэг заалтын хариулт “хязгаарлах нь зөвшөөрөгддөггүй” гэж утгаараа зөв байсан ч түлхүүр үг тараагүй тул скрипт алдаа гэж тооцсон. Харин хуульд байхгүй асуултын зөвхөн 33% (2/6, скриптээр), гараар 50% (3/6, завсар 19-81%)-д зөв татгалзсан нь системийн хамгийн том сул тал юм. Эцсийн шалгалтын хуульд байхгүй асуултуудыг холбоотой үгтэй (“ажилтанд утасны төлбөрийн мөнгө олгох уу?”) болон холбоогүй (“ажилтанд компанийн машин олгох уу?”) гэж зориудаар хавтай бичсэн.

Багц	Хуульд байгаа	Хуульд байхгүй
Хөгжүүлэлт (27+8), 0.6B	85% (23/27)	75% (6/8)
Эцсийн (12+6), скриптээр	75% (9/12)	33% (2/6)
Эцсийн (12+6), гараар	83% (10/12)	50% (3/6)

3-р хүснэгт. Хариултын зөв байдал (зөв зүйл иш татсан байх шаардлагатай)

Заалтыг ч embedding-ээр эрэмбэлэх (заалтын түвшний embedding) хувилбарыг хөгжүүлэлтийн 35 асуулт дээр харьцуулахад 27/35 (77%) гарч, ашиглаагүй хувилбарын 30/35 (86%)-аас муу байсан тул үндсэн тохиргооноос хассан (4-р хүснэгт). Дахин оролдох шат, хамгаалалтуудыг тус тусад нь хассан туршилт хийгээгүй.

Хувилбар	Зөв хариулт (35)
Заалтын embedding-гүй (үндсэн)	30 (86%)
Заалтын embedding-тэй	27 (77%)

4-р хүснэгт. Заалтын түвшний embedding эрэмбийн харьцуулалт

Алдааг шинжилбэл тав төрөлтэй. (а) Хуульд байхгүй асуултад хуурамч хариулт: эцсийн багцад “утасны төлбөр”, “тэжээвэр амьтан” асуултад модель “туслах малчин” гэх мэт хамааралгүй заалтаас хариулт зохиож, “кофе уух завсарлага” асуултад хуульд байхгүй хориг бүтээсэн. Харин холбоотой үггүй асуултад (“компанийн машин”, “спорт заал”) зөв татгалзсан. (б) Утга эсрэгээр хөрвөх: “ослын нөхөн төлбөрийг хоёр болон түүнээс дээш удаа олгохоор хамтын гэрээнд тусгаж болно” гэсэн заалтыг модель “тохирохгүй” гэж хариулсан. (в) Нөхцөл орхигдох: “өөрөө зөвшөөрснөөс бусад тохиолдолд хориглоно” гэсэн заалтыг хөгжүүлэлтийн багцад “тухайн тохиолдолд хориглоно” болгон гажуудуулсан. (г) Ярианы ба хуулийн хэллэгийн зөрүү: “орон тоо цөөрсөн гээд халах” (хуульд “цуцлах”), “гэрээнд ороогүй ажил” (хуульд “тусгаагүй”) асуултад хайлт зөв зүйлийг олдоггүй байв. (д) Загварын Монгол хэлний гажуудал: үг залгагдах, утгагүй өгүүлбэр бий болох тохиолдол гарсан. Хайлтын алдаа ихэнх тохиолдолд “Мэдээлэл олдсонгүй” гэж аюулгүй бүтэлгүйтдэг боловч (б), (в) төрлийн алдаа нь хуулийн лавлагаанд аюултай.

Дүгнэлт

Энэхүү судалгаагаар Хөдөлмөрийн тухай хуулийн лавлах чатботыг RAG аргаар, бүрэн локал орчинд бүтээв. Хуулийн бүтэцтэй (зүйл, заалт) хэсэглэлт, Qwen3-Embedding ба BM25-ыг нэгтгэсэн hybrid хайлт, заалтын түвшний контекст сонголт, тоо баталгаажуулах хамгаалалт нь 4 GB GPU, 8 GB RAM-тай компьютер дээр ажиллах прототипийг бий болгосон. Эцсийн шалгалтаар зөв зүйлийг эхний байранд 92%, эхний тавд 100% олж, хуульд байгаа асуултын 75-83%-д зөв хариулсан.

Үүний зэрэгцээ чухал хязгаарлалт байна. Хуульд байхгүй асуултад хуурамч хариулт зохиох (зөв татгалзал 33-50%), хуулийн утгыг эсрэгээр хөрвүүлэх, нөхцөл орхих нь жижиг (4B) моделийн хязгаар бөгөөд хуулийн лавлагаанд аюултай. Үнэлгээний багц жижиг (эцсийн 18 асуулт, итгэх завсар өргөн), асуултуудыг зохиогчид өөрсдөө бичсэн, мөн хуулийн текстийг цэвэрлэхэд 12 газарт дэд бүлгийн гарчиг заалтын төгсгөлд наалдсан хэвээр үлдсэн. Иймээс систем нь хуулийн зөвлөгөө бус, хариултыг эх заалттай нь тулгаж шалгах лавлах туслах түвшинд байна.

Цаашид (1) асуултыг албан ёсны хуулийн хэлээр дахин бичиж хайх, (2) хариултыг эх заалттай тулган баталгаажуулах нэмэлт шат, (3) илүү том

локал модель, (4) эх заалтын текстийг хариултын хамт харуулах, найдвар багатай хариултыг тэмдэглэх хэрэглэгчийн интерфэйс, (5) бодит хэрэглэгчийн асуултаар үнэлгээний багцыг өргөжүүлж, компанийн дотоод журмыг нэмэх ажлыг төлөвлөж байна.

НОМ ЗҮЙ

[1] Lewis P., Perez E., Piktus A. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems (NeurIPS) - 2020

[2] Robertson S., Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond. Foundations and Trends in Information Retrieval - 2009

[3] Cormack G. V., Clarke C. L. A., Büttcher S. Reciprocal Rank Fusion outperforms Condorcet and individual Rank Learning Methods. ACM SIGIR - 2009

[4] Zhang Y., Li M., Long D., Zhang X. et al. Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models. arXiv:2506.05176 - 2025

[5] Yang A. et al. Qwen3 Technical Report. arXiv:2505.09388 - 2025

[6] Ji Z., Lee N., Frieske R. et al. Survey of Hallucination in Natural Language Generation. ACM Computing Surveys - 2023

[7] Wilson E. B. Probable Inference, the Law of Succession, and Statistical Inference. Journal of the American Statistical Association - 1927

[8] Монгол Улсын Хөдөлмөрийн тухай хууль (шинэчилсэн найруулга). https://legalinfo.mn

[9] Ollama. https://ollama.com

[10] Qwen3.5-4B model card. https://huggingface.co/Qwen/Qwen3.5-4B